2iE - Institut International d'Ingénierie de l'Eau et de l'Environnement

Master Analyse Spatiale avec Machine Learning

MODULE 2

Feature Engineering Spatial

Dr Rodrique KAFANDO

Enseignant Chercheur, Informatique – Intelligence Artificielle

kafando.rodrique@gmail.com

Paramètre	Valeur
Programme	Master ASML — Semestre 1
Volume	CM : 2h | TP : 3h | ECTS : 3 (partiel)
Niveau	Master 1 — prérequis Module 1
Outils	GeoPandas · libpysal · esda · rasterstats · scipy · scikit-learn
Données	GADM 4.1 (45 provinces BF) · Cadre Harmonisé IPC (HDX) · Copernicus FAPAR
Fil conducteur	Construire les variables X qui prédisent les phases IPC 1–5

Objectifs d'apprentissage

Au terme de ce module, vous serez en mesure de :

1. Expliquer pourquoi l'hypothèse d'indépendance des observations est violée sur des données géographiques, et en quoi cela modifie la démarche ML
2. Construire une matrice de poids spatiaux W et calculer un lag spatial sur des données réelles de provinces BF
3. Interpréter un indice de Moran I et des indicateurs LISA pour localiser les hotspots d'insécurité alimentaire
4. Dériver des features géométriques, de distance et spectrales à partir de sources ouvertes (GADM, HOT OSM, Copernicus)
5. Appliquer le VIF pour détecter la multicolinéarité et constituer une feature matrix propre
6. Justifier chaque choix de feature par un mécanisme causal ancré dans le contexte sahélien

1. De la donnée brute à la variable ML : le défi du feature engineering

Le Module 1 vous a appris à charger un shapefile, calculer une superficie, afficher une carte. Ces opérations sont indispensables. Mais un algorithme de machine learning — qu'il s'agisse d'un Random Forest, d'un XGBoost ou d'un réseau de neurones — ne peut pas ingérer directement un polygone de province ou une image Sentinel-2. Il ne comprend que des tableaux de nombres : des lignes d'observations et des colonnes de variables numériques.

Le feature engineering spatial est précisément l'art de combler ce fossé. Il s'agit de traduire des objets géographiques — des frontières, des rasters, des réseaux routiers — en variables numériques que l'algorithme peut utiliser pour apprendre, prédire et généraliser. C'est l'étape la plus critique du pipeline de ML spatial : la qualité des features conditionne la performance des modèles bien davantage que le choix de l'algorithme lui-même.

À retenir

Un modèle ML n'est jamais meilleur que ses features. Un Random Forest entraîné sur des features soigneusement construites surpassera presque toujours un réseau de neurones profond entraîné sur des données brutes mal préparées. Le temps investi dans le feature engineering est toujours rentable.

1.1 Le problème spécifique à l'espace

Le feature engineering classique — pour des données tabulaires non spatiales — consiste à normaliser, encoder et transformer des variables existantes. Le feature engineering spatial ajoute une dimension supplémentaire : l'espace lui-même est une source d'information. La position d'une province, sa forme, ses voisines, sa végétation mesurée par satellite — tout cela est potentiellement prédictif.

Mais l'espace crée aussi un problème fondamental : la dépendance spatiale. Les observations proches géographiquement ont tendance à se ressembler davantage que les observations lointaines. Cette propriété — connue sous le nom de Première Loi de Tobler — viole l'hypothèse d'indépendance des observations sur laquelle repose la plupart des algorithmes ML.

Définition

Première Loi de Tobler (1970) : "Tout est lié à tout, mais les choses proches le sont plus que les choses lointaines." En pratique : deux provinces voisines ont des phases IPC plus similaires que deux provinces distantes, non pas par hasard, mais parce qu'elles partagent le même régime de pluies, les mêmes marchés alimentaires et les mêmes flux de population.

Cette dépendance spatiale est à la fois un problème et une ressource. Un problème, car une validation croisée classique (k-fold aléatoire) surestimera les performances du modèle — les données de test "fuient" de l'information via le voisinage géographique. Une ressource, car le lag spatial — la valeur moyenne des voisines — devient une feature prédictive très puissante.

1.2 Le fil conducteur : prédire les phases IPC au Burkina Faso

Ce module est structuré autour d'une question réelle : quelles variables géospatiales permettent de prédire dans quelle phase d'insécurité alimentaire se trouvera une province du Burkina Faso ? La variable cible — ipc_phase du Cadre Harmonisé — varie de 1 (Minimal) à 5 (Famine). À la fin du module, vous disposerez d'une feature matrix de 45 provinces × 9 variables, prête à être utilisée dans un classifieur du Module 3.

IPC signifie **Integrated Phase Classification** — en français : **Classification Intégrée des Phases.**

C'est un cadre analytique international standardisé qui classe la sévérité de l'**insécurité alimentaire** en 5 phases :

Phase	Niveau	Signification
1	Minimal	Les ménages couvrent leurs besoins alimentaires sans difficultés particulières
2	Stress	Alimentation suffisante mais maintenue grâce à des stratégies d'adaptation
3	Crise	Déficits alimentaires significatifs, dégradation des moyens de subsistance
4	Urgence	Déficits alimentaires sévères, malnutrition aiguë élevée
5	Famine	Mortalité ou malnutrition extrêmes

Au Burkina Faso, ce classement est produit trimestriellement par le **Cadre Harmonisé (CH)**, le système régional d'analyse de l'insécurité alimentaire pour l'Afrique de l'Ouest, piloté par le CILSS et les partenaires (FAO, PAM, FEWS NET).

Contexte terrain — Burkina Faso
Le Cadre Harmonisé (CH) est publié trimestriellement pour l'Afrique de l'Ouest par un réseau d'agences (CILSS, FAO, PAM, FEWS NET). En 2024, environ 60% des provinces du BF étaient classées IPC 2 ou 3, et 20% en IPC 4 (Urgence), essentiellement dans la bande sahélienne Nord-Est. Ce contexte réel donne du sens à chaque feature que nous allons construire.

Section	Feature produite	Mécanisme causal avec IPC
§3 Géométrie	superficie_km2, compacite	Grande province allongée → intervention humanitaire plus difficile
§3 Position	pop_density, zone_bioclim	Forte pression pop + aridité → stress alimentaire amplifié

Section	Feature produite	Mécanisme causal avec IPC
§4 Voisinage	ipc_lag, lisa_cat	Province entourée de crises → risque de contagion alimentaire
§5 Distance	dist_route_km, travel_time_h	Enclavement → pas d'accès aux marchés ni à l'aide d'urgence
§6 Spectral	fapar_mean, fapar_trend	Végétation faible → récolte déficitaire → insécurité alimentaire
§7 Sélection	Feature matrix VIF-validée	Éliminer la redondance → features indépendantes pour le RF

2. Sources de Données et Architecture du Pipeline

Avant d'écrire la moindre ligne de feature engineering, il faut connaître précisément les données disponibles, leur format, leur granularité et leurs limitations. Ce travail de cartographie des sources est souvent négligé — et c'est la cause principale des pipelines qui échouent en production.

2.1 GADM : la base géométrique

GADM (Global Administrative Areas, version 4.1) est la source de référence pour les découpages administratifs mondiaux. Pour le Burkina Faso, il fournit quatre niveaux hiérarchiques emboîtés : le pays (level-0), les 13 régions (level-1), les 45 provinces (level-2) et les 351 communes (level-3). Dans ce module, nous travaillons au niveau des provinces (level-2), qui correspondent à l'échelle de publication du Cadre Harmonisé.

La spécificité technique importante de GADM est que les fichiers sont toujours fournis en EPSG:4326 (WGS84, degrés décimaux). Cela signifie que tout calcul métrique — superficie, périmètre, distance — nécessite une reprojection préalable en EPSG:32630 (UTM Zone 30N, mètres). Nous y reviendrons systématiquement dans chaque section.

Attention
GADM utilise des noms de colonnes génériques (NAME_1, NAME_2) qui doivent être renommés pour être exploitables. Le pipeline standard du cours applique systématiquement la correspondance : NAME_1→region, NAME_2→province, GID_2→gid_province. Cette harmonisation est faite une seule fois dans la fonction load_gadm() et s'applique à tous les notebooks.

2.2 Le Cadre Harmonisé : la variable cible

Le Cadre Harmonisé est bien plus qu'une simple source de données — c'est la synthèse de dizaines d'indicateurs de terrain (consommation alimentaire des ménages, malnutrition aiguë, stratégies de survie, prix des marchés, état des pluies) condensés en une phase IPC de 1 à 5. Prédire cette phase revient à prédire une évaluation d'experts de terrain qui intègre des dimensions économiques, climatiques et humanitaires.

Phase IPC	Niveau	Situation alimentaire des ménages	Prévalence BF (2024)
1	Minimal	Besoins couverts sans stratégie inhabituelle	~10 %
2	Stress	Alimentation suffisante mais adaptation requise	~30 %
3	Crise	Déficits alimentaires, dégradation des actifs	~35 %
4	Urgence	Déficits sévères, émaciation élevée, actifs épuisés	~20 %
5	Famine	Mortalité ou émaciation extrêmes (zones de conflit)	< 5 %

2.3 Sources complémentaires

Source	Contenu	Usage dans ce module	URL
Copernicus FAPAR	Végétation biophysique 300m, mensuel	fapar_mean, fapar_trend (§6)	data.humdata.org (Copernicus)
HOT OSM Roads	Réseau routier complet BF	dist_route_km (§5)	data.humdata.org/hotosm_bfa_roads
WorldPop / GRID3	Population grillée 100m	pop_density (§3)	data.humdata.org (GRID3 2019)
OCHA COD-AB	Limites officielles + P-codes ONU	Jointure alternative au CH	data.humdata.org

2.4 Architecture du pipeline de feature engineering

Le pipeline suivi dans ce module respecte un ordre précis que vous ne devez jamais inverser. Chaque étape dépend des précédentes et produit des sorties utilisées par les suivantes.

```
# Ordre impératif du pipeline M2
1. Chargement GADM + fallback        → gdf (GeoDataFrame propre, CRS 4326)
2. Jointure Cadre Harmonisé          → gdf[ipc_phase, ipc_label]
3. Nettoyage géométrique             → gdf valide (buffer(0), dropna)
4. Features géométriques (to_crs 32630) → superficie_km2, compacite
5. Matrice W + lag spatial           → ipc_lag, lisa_cat
6. Features de distance              → dist_route_km, dist_ville_km
7. FAPAR + zonal_stats               → fapar_mean, fapar_trend
```

8. VIF + sélection → feature matrix (CSV)

À reteni
Ce pipeline produit exactement une ligne par province. Chaque colonne est une feature numérique. La dernière colonne est ipc_phase (la variable cible y). C'est ce tableau qui sera passé directement au classifieur en Module 3.

3. Préparation des Données et Systèmes de Projection

Le nettoyage et l'harmonisation des données sont les étapes les moins spectaculaires du pipeline, mais les plus critiques. Une erreur à ce stade — mauvais CRS, jointure ratée, NaN non traités — se propagera silencieusement dans toutes les features calculées ensuite et biaisera le modèle ML sans qu'on puisse facilement en retrouver la cause.

3.1 Pourquoi le CRS est la première chose à vérifier

Si vous avez retenu une seule règle du Module 1, c'est celle-ci : vérifier le CRS avant toute opération. Mais dans le contexte du feature engineering, cette règle prend une dimension supplémentaire : des features calculées dans le mauvais CRS ne sont pas seulement fausses — elles sont trompeusement précises. Un Random Forest entraîné sur une superficie en degrés carrés au lieu de km² n'affichera aucune erreur ; il apprendra juste une relation biaisée.

EPSG	Système	Unité	Usage correct	Ce qui se passe si mal utilisé
4326	WGS84 Géographique	Degrés	Stockage, échange, Folium	superficie en degrés² — sans sens physique
32630	UTM Zone 30N	Mètres	TOUT calcul métrique BF	—
3857	Web Mercator	Mètres (distordus)	Fonds de carte Contextily	superficies déformées aux latitudes BF

Conseil pratique
Règle mnémotechnique pour le BF : "Je calcule → 32630. Je stocke/affiche → 4326. Fond de carte → 3857." Appliquer to_crs() juste avant l'opération, jamais de façon permanente sur le GeoDataFrame principal. Cela évite d'accumuler les reprojections et de perdre la trace du CRS courant.

3.2 Jointure avec le Cadre Harmonisé : le piège des graphies

La jointure entre GADM et le Cadre Harmonisé est l'étape la plus délicate du pipeline. Les deux datasets nomment les mêmes provinces avec des graphies qui ne correspondent pas toujours exactement. GADM utilise des noms normalisés français avec accents, tandis que le CH peut utiliser des abréviations ou des versions sans accents issues d'une transcription anglaise. La

province "Séno" dans GADM devient parfois "Seno" dans le CH, "Namentenga" peut être "Namenga", etc.

La solution est une normalisation systématique avant toute jointure : tout mettre en minuscules, supprimer les espaces superflus, et convertir les caractères accentués en ASCII. Ces trois opérations ne prennent qu'une ligne chacune mais évitent des heures de débogage.

```
import unicodedata

def normaliser_nom(serie):
    """Normalise une colonne de noms pour jointure robuste."""
    s = serie.str.lower().str.strip()
    # Suppression des accents : NFD décompose les caractères accentués,
    # encode en ASCII ignore les combinaisons diacritiques
    s = s.apply(lambda x: unicodedata.normalize("NFD", str(x))
                        .encode("ascii","ignore").decode("utf-8"))
    return s

# Avant la jointure
gdf["province_norm"] = normaliser_nom(gdf["province"])
ch["province_norm"]  = normaliser_nom(ch["province_ch"])
gdf = gdf.merge(ch[["province_norm","ipc_phase"]], on="province_norm", how="left")

# Contrôle obligatoire : taux de jointure
taux = gdf["ipc_phase"].notna().sum() / len(gdf) * 100
print(f"Taux de jointure : {taux:.1f}%  (< 80% = problème de graphies)")
```

4. Features Géométriques et de Position

La forme et la taille d'une province sont des informations géographiques élémentaires, mais elles ont une valeur prédictive réelle dans le contexte humanitaire. Une province vaste et peu compacte est logistiquement difficile à couvrir lors d'une opération d'aide alimentaire d'urgence. Une province de forte densité de population face à une sécheresse subit un stress alimentaire per capita plus important qu'une province peu peuplée dans les mêmes conditions climatiques.

4.1 Superficie et compacité

La superficie se calcule avec .area sur un GeoDataFrame reprojeté en EPSG:32630. Le résultat est en mètres carrés, qu'on divise par 1 000 000 pour obtenir des km². La compacité de Polsby-Popper mesure le rapport entre l'aire d'un polygone et la surface du cercle ayant le même périmètre. Elle varie de 0 (forme très allongée ou fragmentée) à 1 (cercle parfait).

Définition

Compacité de Polsby-Popper : $C = (4\pi \times \text{aire}) / \text{périmètre}^2$. Une valeur proche de 1 indique une province compacte — facile à couvrir logistiquement. Une valeur faible indique une province allongée ou morcelée — difficile d'accès, où les populations des zones reculées peuvent être laissées pour compte lors d'une crise.

```
# Toujours reprojeter avant .area et .length
gdf_utm = gdf.to_crs(epsg=32630)

gdf["superficie_km2"] = gdf_utm.geometry.area   / 1e6
gdf["perimetre_km"]   = gdf_utm.geometry.length / 1e3
gdf["compacite"]      = (4 * np.pi * gdf_utm.geometry.area
                       / gdf_utm.geometry.length**2)

# Les centroïdes restent en EPSG:4326 (coordonnées géographiques)
gdf["centroid_lon"] = gdf.geometry.centroid.x
gdf["centroid_lat"] = gdf.geometry.centroid.y
```

Contexte terrain — Burkina Faso
Les provinces sahéliennes du Nord-Est (Séno, Oudalan) sont parmi les plus vastes du BF (~13 000–21 000 km²) et présentent des compacités variables. La province de Kadiogo (Ouagadougou) est la plus petite (~2 500 km²) mais la plus densément peuplée. Ces contrastes géométriques se retrouvent dans les profils IPC : la difficulté logistique d'une grande province mal compacte amplifie l'impact d'une crise.

4.2 Zone bioclimatique : encoder la connaissance experte

La latitude est un proxy très fiable du régime pluviométrique au Burkina Faso. Le gradient Nord-Sud est l'un des plus marqués d'Afrique de l'Ouest : de moins de 400 mm/an dans l'extrême Nord sahélien à plus de 1 000 mm/an dans le Sud soudanien. Encoder ce gradient en variable catégorielle permet au modèle ML de distinguer des provinces climatiquement incomparables sans avoir besoin des données pluviométriques elles-mêmes.

Conseil pratique
La zone bioclimatique n'est pas redondante avec la latitude (centroid_lat). La latitude est continue — le modèle doit apprendre lui-même les seuils. La zone bioclimatique encode une connaissance experte préalable : ces seuils (14°, 12.5°, 11°) correspondent aux isohyètes officiels de l'INSD. Ce type d'encodage expert améliore souvent les performances et accélère l'entraînement.

```
def zone_bioclim(lat):
    """Encode le gradient climatique N-S du Burkina Faso.
    Seuils calés sur les isohyètes INSD (pluviométrie annuelle).
    > 14.0° : < 400 mm/an  → Sahélien strict (pastoral dominant)
    > 12.5° : 400-600 mm   → Sahélien (agriculture aléatoire)
    > 11.0° : 600-900 mm   → Soudano-sahélien (agriculture pluviale)
    < 11.0° : > 900 mm     → Soudanien (agriculture + élevage intégrés)
    """
    if  lat > 14.0: return "Sahélien strict"
```

```
    elif lat > 12.5: return "Sahélien"
    elif lat > 11.0: return "Soudano-sahélien"
    else:            return "Soudanien"

gdf["zone_bioclim"] = gdf["centroid_lat"].apply(zone_bioclim)
# Variable catégorielle : à encoder en one-hot avant entraînement ML
# pd.get_dummies(gdf["zone_bioclim"], prefix="zone", drop_first=True)
```

4.3 Densité de population

La densité de population (habitants/km²) capture la pression humaine sur les ressources alimentaires locales. Une province très peuplée avec peu de terres arables par habitant est structurellement vulnérable. À l'inverse, une province peu peuplée dans une zone aride souffre d'une vulnérabilité d'aridité — mais avec moins de bouches à nourrir. Ces deux profils de vulnérabilité distincts justifient d'intégrer pop_density comme feature indépendante.

```
from rasterstats import zonal_stats

# Raster WorldPop BF 2020 — résolution ~100m
# Si disponible en local (download HDX) :
stats_pop = zonal_stats(gdf, "worldpop_bf_2020.tif",
                        stats=["sum"], nodata=-99999)
gdf["pop_total"]   = [s["sum"] or 0 for s in stats_pop]
gdf["pop_density"] = gdf["pop_total"] / gdf["superficie_km2"]

# Note : GADM ne contient pas de colonne population.
# Si WorldPop indisponible : utiliser les données INSD 2019 (recensement BF)
# ou un gradient synthétique centré sur Ouagadougou (voir notebooks TP).
```

5. Dépendance Spatiale : Matrice W, Lag et Moran

C'est la section la plus importante du module — et la plus spécifique à l'analyse spatiale. Les concepts présentés ici n'ont pas d'équivalent dans le ML classique sur données tabulaires. Ils constituent le cœur de ce qui distingue l'analyse spatiale d'une simple régression sur un tableau de chiffres.

5.1 Le problème : l'hypothèse i.i.d. est violée

Tout algorithme de ML supervisé classique fait une hypothèse fondamentale sur ses données : les observations sont indépendantes et identiquement distribuées (i.i.d.). En pratique, cela signifie que la valeur d'une observation ne doit pas dépendre de la valeur de ses voisines. Pour des données tabulaires classiques — transactions bancaires, diagnostics médicaux, avis clients — cette hypothèse est raisonnable.

Pour des données géographiques, elle est systématiquement violée. Les provinces voisines partagent le même régime de pluies, les mêmes marchés transfrontaliers, les mêmes flux de déplacés internes. Une crise alimentaire dans la province de Séno augmente mécaniquement

le risque dans les provinces qui la bordent. Cette dépendance spatiale a deux conséquences directes sur notre pipeline ML.

Attention

Conséquence 1 — Performance : un k-fold classique aléatoire surestimera les performances du modèle de 15 à 40 % selon le degré d'autocorrélation. En Module 3, vous utiliserez une spatial cross-validation (folds géographiques) pour corriger ce biais. Le Moran I calculé ici justifie et calibre cette correction.

Conséquence 2 — Feature : la dépendance spatiale devient une ressource. Le lag spatial ipc_lag — la phase IPC moyenne des provinces voisines — capture exactement cette contagion régionale. Dans les études IPC africaines, c'est systématiquement l'une des features les plus prédictives.

5.2 La matrice de poids W : formaliser le voisinage

Pour quantifier la dépendance spatiale, il faut d'abord formaliser qui est voisin de qui. C'est le rôle de la matrice de poids spatiaux W. Pour n provinces, W est une matrice n×n où W[i,j] = 1 si les provinces i et j sont considérées voisines, et 0 sinon. Après normalisation en ligne, chaque valeur W[i,j] représente le poids accordé à la province j dans le calcul des statistiques de voisinage de la province i.

Définition

Matrice W Queen : deux provinces sont voisines si elles partagent un côté OU un point (sommet) commun de leur polygone GADM. C'est le critère recommandé pour les découpages administratifs, car les frontières de province BF sont souvent irrégulières. La matrice Rook (côté uniquement) est plus adaptée aux grilles régulières.

```
from libpysal.weights import Queen, KNN

# Construction sur les vraies géométries GADM — le voisinage est réel
W = Queen.from_dataframe(gdf, use_index=True)
W.transform = "r"  # Normalisation en ligne : chaque ligne somme à 1

# Diagnostics de base
print(f"Provinces : {W.n}")
print(f"Nb voisins moyen : {W.mean_neighbors:.1f}")

# Provinces sans voisin ("îles topologiques") — à corriger impérativement
if W.islands:
    print(f"⚠️ {len(W.islands)} île(s) → passage à KNN k=4")
    W = KNN.from_dataframe(gdf, k=4)
    W.transform = "r"
```

À retenir

Avec les vraies géométries GADM, la matrice W capture le voisinage réel des provinces. Deux provinces géographiquement éloignées ne seront jamais considérées comme voisines. Avec

des rectangles fictifs (comme les fallback embarqués), le voisinage est artificiel et les résultats de l'autocorrélation sont biaisés. C'est la raison principale pour laquelle les notebooks M2 chargent GADM level-2 en priorité.

5.3 Le lag spatial : transformer la dépendance en feature

Une fois W construite, le lag spatial d'une variable x pour la province i est défini par :

```
    lag_x[i] = ∑□ W[i,j] × x[j]

# Soit : la moyenne pondérée de x dans le voisinage immédiat de i
```

Le lag spatial n'est pas une redondance : ipc_phase[i] et ipc_lag[i] mesurent deux choses fondamentalement différentes. ipc_phase[i] décrit la situation actuelle de la province i. ipc_lag[i] décrit la pression exercée par son environnement régional. Ces deux informations sont complémentaires et souvent faiblement corrélées.

Contexte terrain — Burkina Faso
Exemple concret : la province de Bam (Centre-Nord) peut être en phase IPC 2 (Stress) localement, tout en ayant ipc_lag = 3.5 si ses voisines Sanmatenga et Namentenga sont en phase 3-4. Ce différentiel signale un risque de détérioration imminente — une information invisible sans le lag spatial.

```
from libpysal.weights import lag_spatial

# Toujours combler les NaN avant le lag (libpysal ne gère pas les NaN)
ipc_vals = gdf["ipc_phase"].fillna(gdf["ipc_phase"].median()).values
gdf["ipc_lag"] = lag_spatial(W, ipc_vals)

# Lag FAPAR : lissage spatial de la végétation (utile si raster bruité)
gdf["fapar_lag"] = lag_spatial(W, gdf["fapar_mean"].fillna(0).values)
```

5.4 L'indice de Moran I : mesurer l'autocorrélation

L'indice de Moran I est le test statistique de référence pour mesurer l'autocorrélation spatiale globale d'une variable. Sa valeur s'interprète ainsi : proche de +1 = les valeurs similaires sont regroupées géographiquement (clustering) ; proche de 0 = distribution aléatoire ; proche de -1 = les valeurs s'alternent (damier). La p-valeur, calculée par permutation Monte Carlo, indique si ce clustering est statistiquement significatif.

Définition
Formule de Moran I :
$I = (n / S_0) \times (\sum_i \sum\square W[i,j](x_i-\bar{x})(x - \bar{x})) / (\sum_i(x_i-\bar{x})^2)$
Où n = nombre d'observations, S_0 = somme de tous les poids, $\bar{x}$ = moyenne de x.
Une valeur I > 0.30 avec p < 0.05 sur les phases IPC BF indique un clustering fort et justifie l'usage d'une spatial cross-validation en Module 3.

```
from esda.moran import Moran, Moran_Local

# Test de Moran I global (999 permutations par défaut)
moran = Moran(ipc_vals, W)
print(f"I = {moran.I:.4f}  |  p = {moran.p_sim:.4f}  |  Z = {moran.z_sim:.2f}")

# Interprétation
if moran.p_sim < 0.05 and moran.I > 0:
    print("Clustering spatial significatif.")
    print("→ Spatial CV obligatoire en Module 3.")
    if moran.I > 0.30:
        print("→ Clustering fort : séparer les folds géographiquement.")
```

5.5 Les indicateurs LISA : localiser les hotspots

Le Moran I global résume en un seul chiffre l'autocorrélation de l'ensemble du territoire. Les indicateurs LISA (Local Indicators of Spatial Association), proposés par Anselin (1995), décomposent ce signal global en contributions locales par province. Chaque province reçoit une catégorie LISA qui la positionne dans l'un des quatre quadrants du diagramme de Moran.

Quadrant LISA	Condition	Signification terrain BF
HH (High-High)	ipc[i] élevé + voisines élevées	Cluster de crise — hotspot humanitaire (Nord-Est sahélien)
LL (Low-Low)	ipc[i] faible + voisines faibles	Cluster de résilience — coldspot (Sud soudanien)
HL (High-Low)	ipc[i] élevé + voisines faibles	Province en crise isolée — choc local (conflit, inondation)
LH (Low-High)	ipc[i] faible + voisines élevées	Province stable entourée de crises — risque de contagion
NS	p > 0.05	Non significatif — pas de structure spatiale locale

```
lisa = Moran_Local(ipc_vals, W, seed=42)

gdf["lisa_q"]   = lisa.q        # Quadrant : 1=HH 2=LH 3=LL 4=HL
gdf["lisa_p"]   = lisa.p_sim    # p-valeur par permutation
gdf["lisa_cat"] = gdf.apply(
    lambda r: {1:"HH",2:"LH",3:"LL",4:"HL"}.get(int(r["lisa_q"]),"NS")
```

```
        if r["lisa_p"] < 0.05 else "NS", axis=1)

# Variable catégorielle : encoder en one-hot avant ML
# pd.get_dummies(gdf["lisa_cat"], prefix="lisa", drop_first=True)
```

6. Features de Distance et d'Accessibilité

L'enclavement géographique est l'un des déterminants les mieux documentés de la vulnérabilité alimentaire en Afrique de l'Ouest. Une province sans accès routier praticable ne peut pas bénéficier de l'approvisionnement des marchés lors d'un déficit local, et les convois d'aide humanitaire mettent plus de temps à l'atteindre. Les études du CILSS montrent une corrélation directe entre la distance aux axes bitumés et les délais de réponse humanitaire lors des crises sahéliennes.

6.1 Distance au réseau routier (HOT OSM)

La distance de chaque province au tronçon routier le plus proche est calculée depuis le centroïde de la province vers l'union géométrique de tous les tronçons du réseau HOT OSM. Cette opération utilise la méthode .distance() de GeoPandas sur des géométries en EPSG:32630 — d'où la reprojection préalable obligatoire.

Attention
Le fichier HOT OSM roads pour le BF fait environ 50 Mo. Sur Colab avec une connexion lente, le téléchargement peut prendre plusieurs minutes. Les notebooks prévoient un fallback avec 6 axes routiers principaux simulés (Ouaga–Bobo, Ouaga–Ouahigouya, etc.) si le téléchargement échoue. Ce fallback est moins précis mais capture le gradient d'enclavement N-S.

```
# Chargement réseau routier HOT OSM (ou fallback)
URL_ROADS = "https://data.humdata.org/dataset/hotosm_bfa_roads/..."

try:
    roads = gpd.read_file(URL_ROADS)
    roads_utm = roads.to_crs(32630)
    roads_union = roads_utm.geometry.unary_union
    src_roads = "HOT OSM"
except:
    roads_union = make_axes_fallback()  # 6 axes simulés
    src_roads   = "axes simulés"

# Distance centroïde → réseau le plus proche (en km)
gdf_utm = gdf.to_crs(32630)
gdf["dist_route_km"] = gdf_utm.geometry.centroid.distance(roads_union) / 1e3
```

6.2 Distance aux centres urbains (cKDTree)

La cKDTree (Compressed K-Dimensional Tree) de scipy est une structure de données pour la recherche de voisins les plus proches en temps O(log n). Elle est particulièrement efficace quand on calcule les distances entre un grand nombre de points requête (centroïdes de provinces) et un ensemble fixe de cibles (villes).

```
from scipy.spatial import cKDTree
from pyproj import Transformer

# Villes principales BF — coordonnées (lat, lon) WGS84
VILLES = {
   "Ouagadougou":   (12.3647, -1.5243),
   "Bobo-Dioulasso": (11.1771, -4.2978),
   "Koudougou":     (12.2525, -2.3683),
   "Ouahigouya":    (13.5742, -2.4197),
   "Dori":          (14.0350,  0.0343),
}

# Conversion WGS84 → UTM 30N pour les villes
tf = Transformer.from_crs(4326, 32630, always_xy=True)
villes_xy = np.array([tf.transform(lon,lat) for lat,lon in VILLES.values()])
prov_xy   = np.array([(g.centroid.x,g.centroid.y) for g in gdf_utm.geometry])

tree = cKDTree(villes_xy)
dists, idx = tree.query(prov_xy, k=1)   # k=1 : ville la plus proche
gdf["dist_ville_km"] = dists / 1e3
gdf["ville_proche"]  = [list(VILLES.keys())[i] for i in idx]
```

6.3 Temps de trajet vers les services de santé

La distance à vol d'oiseau et le temps de trajet réel divergent considérablement dans les zones rurales du Sahel, où la qualité des pistes varie enormément selon la saison. Le dataset "Motorised Travel Time to Health Facility" (Data for Children Collaborative, HDX) fournit un raster à 100m de résolution du temps de trajet motorisé en secondes, intégrant la qualité des routes et le relief.

```
from rasterstats import zonal_stats

# GeoTIFF : temps de trajet en secondes vers le centre de santé le plus proche
stats_tt = zonal_stats(gdf, "travel_time_health_bf.tif",
                       stats=["mean","max"], nodata=-9999)
gdf["travel_time_mean_s"] = [s["mean"] or 0 for s in stats_tt]
gdf["travel_time_mean_h"] = gdf["travel_time_mean_s"] / 3600
# Interprétation : > 3h = enclavement sanitaire sévère
```

7. Features Spectrales : FAPAR et Végétation

La végétation mesurée par satellite est le proxy le plus direct de la production agricole dans les zones d'agriculture pluviale comme le Burkina Faso, où plus de 90 % de la production céréalière dépend des précipitations. Un faible indice de végétation en juillet-août — au pic de la saison des pluies — est un indicateur quasi-certain d'une récolte déficitaire à venir.

7.1 NDVI vs FAPAR : pourquoi choisir le FAPAR pour le Sahel

Le NDVI (Normalized Difference Vegetation Index) est l'indice de végétation le plus connu. Il est simple, bien documenté et disponible depuis les années 1970. Mais il présente un défaut important pour notre application : il sature à haute densité végétale. Une forêt dense et une savane modérément verte peuvent avoir le même NDVI. En zone sahélienne où les valeurs de végétation sont toujours faibles, cette saturation n'est pas problématique — mais le NDVI reste un indicateur spectral empirique sans base biophysique directe.

Le FAPAR (Fraction of Absorbed Photosynthetically Active Radiation) est la fraction du rayonnement solaire photosynthétiquement actif réellement absorbée par les plantes pour la photosynthèse. C'est une grandeur biophysique mesurable directement : il varie de 0 (sol nu) à 1 (absorption totale). Copernicus le produit à 300m de résolution, mensuel, pour l'ensemble de l'Afrique.

Indice	Type	Plage	Saturation	Interprétation directe	Recommandé Sahel
NDVI	Spectral empirique	[-1, 1]	Oui (>0.5)	Non (ratio spectral)	⚠️ Acceptable
FAPAR	Biophysique	[0, 1]	Non	Oui (fraction photosynthèse)	✅ Recommandé
SAVI	Spectral corrigé	[-1, 1]	Oui	Non (corrige sol aride)	✅ Bon fallback
NDWI	Spectral eau	[-1, 1]	Non	Partielle (eau de surface)	✅ Complémentaire

> 📖 **À retenir**
> Pour le Burkina Faso, le FAPAR est le meilleur proxy de la production agricole disponible en open source. Il est plus précis que le NDVI car il mesure directement ce qui compte : la quantité d'énergie solaire convertie en biomasse végétale. Un FAPAR < 0.15 en juillet (pic de saison des pluies) indique une végétation quasi absente — signal d'une récolte quasi certaine déficitaire.

7.2 Statistiques zonales : du raster à la feature tabulaire

Un raster continu ne peut pas être directement utilisé comme feature dans un modèle ML par province. La bibliothèque rasterstats calcule des statistiques agrégées (moyenne, écart-type, min, max) d'un raster dans chaque polygone d'un GeoDataFrame. C'est le pont technique entre les deux mondes.

La condition préalable est que le vecteur (GeoDataFrame) et le raster (GeoTIFF) soient dans le même CRS. GADM et les rasters Copernicus sont tous les deux en EPSG:4326 — pas de reprojection nécessaire. Si vous utilisez un raster en EPSG:32630, reprojetez d'abord le GeoDataFrame.

```
from rasterstats import zonal_stats
import rasterio

# Calcul FAPAR moyen, std, min, max par province
# gdf en 4326 + raster en 4326 → OK sans reprojection
stats = zonal_stats(gdf, "fapar_bfa_2024_07.tif",
                    stats=["mean","std","min","max"],
                    nodata=-9999.0)

gdf["fapar_mean"] = [s["mean"] for s in stats]
gdf["fapar_std"]  = [s["std"]  for s in stats]

# fapar_std élevé = forte hétérogénéité intra-provinciale
# Les stats de province cachent des sous-zones contrastées
```

7.3 La tendance FAPAR : un signal précurseur à long terme

La valeur de FAPAR à un instant donné capture la situation végétale de la campagne en cours. Mais une tendance décroissante sur plusieurs années est un signal de dégradation structurelle des terres — désertification, surpâturage, déforestation — que la valeur instantanée ne peut pas capturer. La tendance FAPAR est donc une feature complémentaire, et non redondante, avec la valeur instantanée.

On calcule cette tendance en ajustant une régression linéaire sur la série mensuelle FAPAR (12 valeurs par province). La pente de cette droite est la feature. Une pente négative indique une dégradation progressive, une pente positive un verdissement (reboisement ou amélioration du régime de pluies).

```
from scipy.stats import linregress
import numpy as np

# fapar_series[i, m] = FAPAR moyen de la province i au mois m
# Shape : (n_provinces, 12)
months = np.arange(1, 13)

def tendance_fapar(serie_12_mois):
    """Retourne la pente de la régression linéaire mois → FAPAR."""
    slope, _, r, p, _ = linregress(months, serie_12_mois)
    return slope  # unités : FAPAR/mois

gdf["fapar_trend"] = [tendance_fapar(fapar_series[i]) for i in range(len(gdf))]
# fapar_trend < -0.005 / mois → signal de dégradation significative
# fapar_trend > +0.003 / mois → verdissement détectable
```

🌍 **Contexte terrain — Burkina Faso**
Des études récentes sur le Sahel BF (ACMAD, 2022) montrent que les provinces avec fapar_trend < -0.003/mois sur 10 ans ont un risque IPC 3-4 significativement plus élevé à l'horizon suivant, indépendamment de la pluviométrie annuelle. La tendance capte une dégradation cumulative que le FAPAR instantané ne voit pas.

8. Sélection de Features et Feature Matrix Finale

Après avoir calculé l'ensemble des features, deux risques persistent : la redondance (deux features qui mesurent la même chose et dont l'une est superflue) et la malédiction de la dimensionnalité (trop de features pour trop peu d'observations). Avec 45 provinces et une dizaine de features, nous sommes proches de la limite acceptable.

8.1 La multicolinéarité et le VIF

La multicolinéarité — la corrélation élevée entre features — est un problème qui biaise l'interprétation des modèles (importances de features faussées) et peut déstabiliser certains algorithmes (SVM, régression logistique). Le Facteur d'Inflation de la Variance (VIF) mesure à quel point chaque feature peut être prédite linéairement par les autres features.

Définition
VIF[j] = 1 / (1 − R^2) où R^2 est le coefficient de détermination de la régression de x sur toutes les autres features. Un VIF de 1 signifie aucune corrélation. Un VIF de 10 signifie que la feature j partage 90% de sa variance avec les autres. Règle : VIF < 5 acceptable, 5–10 à surveiller, > 10 à exclure.

```
from statsmodels.stats.outliers_influence import variance_inflation_factor
from sklearn.preprocessing import MinMaxScaler
import pandas as pd

FEATURES = ["superficie_km2","pop_density","compacite",
            "fapar_mean","fapar_std","fapar_trend",
            "ipc_lag","dist_route_km","dist_ville_km"]

X_raw  = gdf[FEATURES].dropna()
# Normalisation obligatoire avant VIF
# (le VIF est sensible aux échelles — une feature en km² et une en [0,1)
# auront des VIF artificiellement différents sans normalisation)
X_norm = MinMaxScaler().fit_transform(X_raw)

vif = pd.DataFrame({
   "Feature": FEATURES,
   "VIF": [variance_inflation_factor(X_norm, i)
```

```
        for i in range(X_norm.shape[1])]
}).sort_values("VIF", ascending=False)
print(vif.to_string(index=False))

# Exclure les features avec VIF > 10 (redondantes)
haut_vif = vif[vif["VIF"] > 10]["Feature"].tolist()
feats_finales = [f for f in FEATURES if f not in haut_vif]
```

Conseil pratique
Dans la pratique BF, dist_ville_km et dist_ouaga_km sont souvent redondantes (Ouagadougou est la ville la plus proche de la moitié des provinces). Garder dist_route_km qui capture l'enclavement physique réel. De même, fapar_mean et fapar_lag peuvent être corrélés, vérifier le VIF.

8.2 Feature matrix finale et export

La feature matrix est le produit fini du module. C'est un tableau simple, une ligne par province, dont chaque colonne est une feature numérique normalisée, et dont la dernière colonne est la variable cible ipc_phase. Ce fichier CSV sera l'entrée directe du Module 3.

```
TARGET = "ipc_phase"  # Variable cible — Cadre Harmonisé IPC 1-5

X_fin = MinMaxScaler().fit_transform(gdf[feats_finales].dropna())
export = pd.DataFrame(X_fin, columns=feats_finales)
export["ipc_phase"] = gdf["ipc_phase"].dropna().values
export["province"]  = gdf["province"].dropna().values

export.to_csv("M2_feature_matrix_BF.csv", index=False)
print(f"Feature matrix : {export.shape[0]} provinces x {len(feats_finales)} features")
```

À retenir
ipc_phase (1–5) est une variable ordinale : la classe 3 est "entre" 2 et 4, pas équidistante des autres. En Module 3, vous testerez les deux approches : classification multiclasses (5 classes) et régression ordinale (qui respecte l'ordre). La régression ordinale produit souvent de meilleures métriques sur ce type de données.

9. Bonnes Pratiques et Erreurs Fréquentes

9.1 Les dix erreurs les plus fréquentes

#	Erreur	Conséquence	Correction
1	Calculer superficie/distance en EPSG:4326	Valeurs en degrés — sans sens physique, silencieux	to_crs(32630) avant .area ou .distance()
2	CRS vecteur ≠ CRS raster avant zonal_stats	Statistiques décalées — résultats faux sans erreur	Vérifier gdf.crs == raster CRS
3	NaN dans ipc_phase avant Moran	libpysal plante ou produit NaN en cascade	fillna(median) avant Moran et lag_spatial
4	Provinces sans voisin W (îles topologiques)	ipc_lag = NaN pour ces provinces	Détecter W.islands → fallback KNN k=4
5	VIF calculé sans normalisation	VIF artificiellement biaisés par les échelles	MinMaxScaler() avant variance_inflation_factor
6	Mêmes données en train et test (k-fold classique)	Performance surestimée de 15-40%	Spatial CV en Module 3
7	dist_ouaga_km + dist_ville_km redondantes	Multicolinéarité → VIF élevé → importance faussée	VIF → garder une seule
8	Jointure GADM/CH sans normalisation des noms	Taux jointure < 80% → features IPC manquantes	normaliser_nom() avant merge
9	Raster Rasterio : src.read(0) au lieu de src.read(1)	IndexError ou lecture mauvaise bande	Bandes Rasterio commencent à 1
10	f-string triple-quote dans notebook pour popup Folium	Bug de syntaxe silencieux	Concaténation de strings

9.2 Fonction de contrôle qualité

Prenez l'habitude d'appeler cette fonction après chaque étape majeure du pipeline. Ces quelques secondes de vérification évitent des heures de débogage.

```
def check_features(gdf, features, target="ipc_phase", label="Pipeline"):
    print(f"=== {label} ===")
    print(f"  Provinces   : {len(gdf)}")
    print(f"  CRS         : {gdf.crs}")
    feats_ok = [f for f in features if f in gdf.columns]
    feats_ko = [f for f in features if f not in gdf.columns]
```

```
print(f"  Features OK  : {len(feats_ok)} / {len(features)}")
if feats_ko: print(f"  ⚠️ Manquantes : {feats_ko}")
nan_counts = gdf[feats_ok].isnull().sum()
nan_feats  = nan_counts[nan_counts > 0]
if len(nan_feats) > 0: print(f"  ⚠️ NaN : {nan_feats.to_dict()}")
else: print("  NaN : aucun ✅")
if target in gdf.columns:
    print(f"  ipc_phase    : {gdf[target].notna().sum()}/{len(gdf)} non-NaN")
```

9.3 Vers le Module 3

La feature matrix produite dans ce module sera l'entrée directe du Module 3 (ML Classique Spatial). Les étapes suivantes seront : (1) Random Forest et XGBoost sur la feature matrix, (2) spatial cross-validation justifiée par le Moran I calculé ici, (3) interprétabilité via SHAP values — quelles features prédisent le mieux les phases IPC ?, (4) carte de prédiction IPC pour les provinces sans données CH récentes.

À retenir
Résultat attendu en Module 3 : les features de voisinage (ipc_lag, lisa_cat) et la végétation (fapar_mean) devraient figurer dans le top-3 des features importantes du Random Forest. Cela validera rétrospectivement le travail de construction de W et le choix du FAPAR comme indicateur de végétation.

Références et Sources

- Anselin, L. (1995). Local indicators of spatial association — LISA. Geographical Analysis, 27(2), 93–115.
- Tobler, W. (1970). A computer movie simulating urban growth in the Detroit region. Economic Geography, 46, 234–240.
- IPC (2024). Integrated Phase Classification — Manuel technique v3.1. fews.net
- GADM (2023). Global Administrative Areas, version 4.1. geodata.ucdavis.edu
- Réseau CH (2024). West & Central Africa Food Security Data — Cadre Harmonisé. data.humdata.org
- Copernicus (2024). Burkina Faso FAPAR — Global Land Service. land.copernicus.eu
- Documentation libpysal + esda : pysal.org | Documentation rasterstats : pythonhosted.org/rasterstats
- Bivand R. et al. (2013). Applied Spatial Data Analysis with R, 2e éd. Springer.
- Rey S., Anselin L. (2010). PySAL: A Python Library of Spatial Analytical Methods. RSSA.